

1) Вогнутое множество: мн-во S вогнуто, если $\forall x_1, x_2 \in S$ отрезок между ними лежит в S : $\forall \theta \in [0, 1] \quad \forall x_1, x_2 \in S \Rightarrow \theta x_1 + (1-\theta)x_2 \in S$

2) Вогнутая функция: $f(x)$, опр. на вогн. $S \subset \mathbb{R}^n$, наз. вогн. на S , если $f(\lambda x_1 + (1-\lambda)x_2) \geq \lambda f(x_1) + (1-\lambda)f(x_2) \quad \forall x_1, x_2 \in S, \lambda \in [0, 1]$

3) μ -сильно вогн. функция: $f(x)$, опр. на вогн. мн-ве $S \subset \mathbb{R}^n$, наз. μ -сильно вогнутой на S , если $f(\lambda x_1 + (1-\lambda)x_2) \geq \lambda f(x_1) + (1-\lambda)f(x_2) - \frac{\mu}{2}\lambda(1-\lambda)\|x_1 - x_2\|^2 \quad \forall x_1, x_2 \in S, \lambda \in [0, 1], \mu > 0$

4) Необход. и дост. усл. макс. экстремума: пусть f - гравит. выпр. в окрестности x^* . Необход.: $\nabla f(x^*) = 0, \nabla^2 f(x^*) \geq 0$; достаточн.: $\nabla f(x^*) = 0, \nabla^2 f > 0$

5) Критерий Ферма: x^* - глобальный min $f \Leftrightarrow 0 \in \partial f(x^*)$ субдифф. f

6) Метод градиентного спуска: для задачи $\min_{x \in \mathbb{R}^n} f(x)$ м.г.с. поправ. послед. по прав. $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$, α_k - размер шага

7) Наскорректированный спуск: градиентный спуск $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$ в котором шаг на каждой итерации выб. мин. поиском $\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$

8) L -гладкость: f наз. L -гладкой, если ее градиент L -липп. $\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2$

9) Липш. неравенство: $\forall x, y \quad f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|^2$ (при L -гладк. ф.)
 L -г. ф-ция всегда ограничена сверху параболой с крив. L , кас. граф.

10) Условие Рунге-Лазаревича: f удовл. усл. РЛ с $\mu > 0$, если $\|\nabla f(x)\|^2 \geq \mu(f(x) - f(x^*)) \quad \forall x$, где x^* - иск. г. min $f^* = f(x^*)$

11) Хар. св. гр. спуска для м. вогн. ф в терм. O (числа итер.):

$\|\nabla f(x_k)\|^2 \sim O(\frac{1}{k}) \Rightarrow$ где достигн. мин $\|\nabla f(x_k)\|^2 \leq \varepsilon$ при $k \sim O(\frac{1}{\varepsilon})$ итер.

12) Для вогн.: где L -гладкой вогнутой функцией или $\uparrow$

погр. $0 < \alpha \leq \frac{1}{L}$ г.с. с. по зрял. ф.: $f(x_k) - f^* \sim O(\frac{1}{k}) \Rightarrow$

$\Rightarrow$ где достигнуто $f(x_k) - f^* \leq \varepsilon$ пред. $k_\varepsilon \sim O(\frac{1}{\varepsilon})$ сг. (судим. с.)

13) Где сильно-кон. ф.: Где L -мажор. μ -сильн. кон. ф. г.с. с. ит.
 $\|x_k - x^*\|^2 \sim O\left((1 - \frac{\mu}{L})^k\right) \Rightarrow$ где дост. точн. ε пред. $k_\varepsilon \sim O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$ сг.

14) Сходимость г.с. где сильно-кон. кв. функций, одн. гиперпл.:

Рассм. заг. кв. оптимиз.: $\min_x f(x) = \min_x \frac{1}{2} x^T A x - b^T x + c$, $A \in S_{++}^d$

$c, \mu = \lambda_{\min}(A)$, $L = \lambda_{\max}(A)$; г.с. $x_{k+1} = x_k - \alpha \nabla f(x_k)$ сходим. при $\frac{d}{dx} f(x)$

$0 < \alpha < \frac{2}{L}$, одн. шаг: $\alpha^* = \frac{2}{\mu + L}$, $\|x_k - x^*\|_2 \leq \left(\frac{L - \mu}{L + \mu}\right)^k \|x_0 - x^*\|_2$

15) Плотные оценки где минимиз. мажор. кон. ф. с пом.

мет. 1 порядка в терм. Ω от числа итераций: рассм. семейства

продв. мет. 1 порядка $x_{k+1} = x_0 + L \cdot \Pi(\nabla f(x_0), \nabla f(x_1), \dots, \nabla f(x_k))$

Где L -м. кон. ф. $f(x_k) - f^* = O(\frac{1}{k^2}) \Rightarrow k_\varepsilon = O(\frac{1}{\sqrt{\varepsilon}})$ Тогда

$\exists f$ - L -м. кон.: $\forall$ метода из сем. $\forall 1 \leq k \leq \frac{n-1}{2} \leq f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|_2^2}{32(k+1)^2}$

16) -- сильно-кон. (PL) ф.: при произ. мет. 1 порядка $\alpha = \frac{1}{L}$

$x_k \in x_0 + L \cdot \Pi(\nabla f(x_0), \dots, \nabla f(x_k)) \Leftrightarrow f(x_k) - f^* = O\left(\left(\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}\right)^{2k}\right) \Rightarrow k_\varepsilon = O\left(\frac{1}{\sqrt{\alpha}} \log \frac{1}{\varepsilon}\right)$

Тогда: $\forall x_0 \forall \mu > 0, \frac{L}{\mu} \geq 1 \exists f$ - L -м. μ -с. кон.: $\forall$ метода из семейства

$\|x_k - x^*\|_2 \geq \left(\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}\right)^k \|x_0 - x^*\|_2$, $f(x_k) - f^* \geq \frac{\mu}{2} \left(\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}\right)^{2k} \|x_0 - x^*\|_2^2$

17) Огмт. уск. мет. с. от резул.: альтернатива $\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}$

$k_\varepsilon = O\left(\frac{1}{\sqrt{\alpha}} \log \frac{1}{\varepsilon}\right) \Leftrightarrow \frac{\alpha-1}{\alpha+1}$, $k_\varepsilon = O\left(\alpha \log \frac{1}{\varepsilon}\right)$, т.е. $\alpha \rightarrow \infty$ (с.б.с.с.)

18) Через мет. пер. пор. и элементов при минимиз. кв. ф-ии:

$f(x) = \frac{1}{2} x^T A x - b^T x$, $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$, ошибка $e_k = x_k - x^*$

заг. полиномом $e_k = p_k(A)e_0$ $p_k(\alpha) = \prod_{i=1}^k (1 - \alpha \cdot \alpha_i)$ $p_k(0) = 1$

т.е. подбор. метод (шагов α_i) $\Leftrightarrow$ подбор м-та p_k с усл. $p_k(0) = 1$

19) Крит. (минимакс) свойства полин. Чебышёва: среди алгебр.

степенн k с нормировкой $p(0) = 1$ оптималь. полином

Чебышёва наименее уск. от нуля на отрезке $[u, L]$

20) Метод рунд-мар. для кв. ф.; Характер сходимости, оптимальные гиперпараметры: $x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta (x_k - x_{k-1})$, где μ -сильно вып. L -маркой кв. функции с опт. пар. $\alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}$, $\beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2$ метод с. линейно: $\|x_k - x^*\|_2 \leq \left(\frac{\sqrt{L}-1}{\sqrt{L}+1}\right)^k \|x_0 - x^*\|$, $k_\varepsilon = O(\sqrt{L} \log \frac{1}{\varepsilon})$

21) Формулировка уск. и. Гестерова для вып. марк. ф.: f -вып. и L -маркая, шаг: $x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$, $\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$, $\delta_k = \frac{\lambda_{k-1}}{\lambda_{k+1}}$
 $y_{k+1} = x_{k+1} + \delta_k (x_{k+1} - x_k)$

22) Характер с. уск. гр. мет. Гестерова для вып. м. ф. в перм. $O(\sqrt{L} \log \frac{1}{\varepsilon})$

Для вып. L -маркой ф. f у.м.т. с. со с. $O(\frac{1}{k^2})$,
 $f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2} = O\left(\frac{1}{k^2}\right)$, $k_\varepsilon = O\left(\frac{1}{\sqrt{\varepsilon}}\right)$

23) Перм. у.г.м.т. для сильно-вып. маркой ф.: пусть f - μ -сильно выпуклая L -маркая, шаг $x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$, $y_{k+1} = x_{k+1} + \gamma (x_{k+1} - x_k)$,
 $\gamma = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$

24) Хар. с. утмк для с-в., м. ф-ий в перм. (числа ст.): для μ -с.в. L -маркой f утмк с. лмт. с уск. зрм.: $f(x_k) - f^* \leq L\|x_0 - x^*\|^2 \left(1 - \sqrt{\frac{\mu}{L}}\right)^k$
 $k_\varepsilon = O(\sqrt{L} \log \frac{1}{\varepsilon})$

25) Метод Ньютона: МН-оптимизируемые локальные квадр. аппрокс. Возьмем кв. прил. в окр. x_k : $f_{x_k}^I(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle$ и найдем точку x_{k+1} , минимиз. пред. $\nabla f_{x_k}^I(x_{k+1}) = 0 \Rightarrow x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$, при этом процесс рекуррентен и порождает снр.

26) С. метод Ньютона для кв. функции: для кв. зрм $\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T A x - B^T x$, $\lambda(A) \in [\mu, L]$ рассмотрим постр. $\nabla^2 f = A \Rightarrow$ МН находит в стая. точку $x_{k+1} = A^{-1}B$, где $\nabla f = 0$, это мин при $A > 0$

27) Характеристика ММ для существования м.р.: Для строго вып. функции мин. зупр. ф-ии с М-мнж. расс. метод Рунге-Кутты с. к x^* с локальной кб. скоростью: при $\|x_0 - x^*\| < \frac{2\mu}{L}$ верно

$$\|x_{k+1} - x^*\| \leq \frac{L}{2\mu} \|x_k - x^*\|^2$$

28) Эмпр. ММ: $x_{k+1} = x_k - \alpha_k [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$, где α_k подбирается процедурой мин. поиска, с. стабилизируя глобальный, бднжн рещ. $\alpha_k \rightarrow 1$ и восп. кб. сходимость метода ММ

29) Метод BFGS: итеративный метод $p_k = -f_k \nabla f(x_k)$, α_k из усл. Армико + кривизна, т.е. Рунге, $x_{k+1} = x_k + \alpha_k p_k$. Обозн. $S_k = x_{k+1} - x_k$,

$y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$, $\rho_k = \frac{1}{y_k^T S_k} \Rightarrow$ обновление обратной матрицы $H_{k+1} = (I - \rho_k S_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k S_k S_k^T$, сопр. > 0 , слож. $O(n^2)$

Локальная сверхлинейная сходимость $\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \rightarrow 0$

Армико: $f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$
 Кривизна: $\nabla f(x_k + \alpha p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k$ } характеризуют это шаг не мал и не велик

30) Основное идея L-BFGS: не хранить матрицу H_k , а хранить m последних пар (S_i, y_i) и вычислять $H_k \nabla f(x_k)$ некоем через рекурсию двух циклов, память $O(mn)$, при фикс. $m \ll n$ мин. сходимость, при $m=n$ совп. с полным BFGS

31) Евклидова проекция $y \in \mathbb{R}^n$ на $S \subseteq \mathbb{R}^n$ $\text{proj}_S(y) = \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2$

32) Форт. усл. $\exists$ проекция г. на м-во: Если $S \subseteq \mathbb{R}^n$ - замкнутое мн-во, то проекция на S $\exists$ $\forall$ точки

33) Форт. усл. единств. проекция г. на м-во: Если $S \subseteq \mathbb{R}^n$ - замкнутое вып. м-во, то проекция на S единственна $\forall$ точки

34) Метод проекции градиента: $\min_{x \in S} f(x)$: $x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$

35) Критерий проекции точки на вып. м-во (теор-во БУГ):

Пусть $S \subseteq \mathbb{R}^n$ - замкн. вып. м-во $\forall x \in S, y \in \mathbb{R}^n$ с

С $\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0$, т.е. тупой угол между вект.

36) Проекц. как линейн. оператор: $\neq$ воз. кернет, если ось лини.

с $L \leq 1$. Опер. проекции на замкн. вып. множество кернетер:

$$\| \text{proj}(x) - \text{proj}(y) \|_2 \leq \| x - y \|_2 \text{ из БУГ}$$

37) Хар. сходимости мет. пр. прог. где градиент вып. ф. в терм. 0:

где вып. L-м. ф. с шагом $\frac{1}{L}$ скор. сублим. со скор. $O(\frac{1}{k})$

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}$$

38) — вып. градиентально-вып. ф.: где μ -сильно-выпукло

L-градиент ф. шаг с шагом $\alpha \leq \frac{1}{L}$ с лин.:

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

39) Метод Франк-Вульфа: решает $\min_{x \in S} f(x)$ без проекций, исп. ортакл
линейной минимизации: $y_k = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$, $x_{k+1} = \delta_k x_k + (1 - \delta_k) y_k$

40) Хар. сх. ФВ где m. вып. ф в терм. 0: где выпукло L-градиент

ф. метод ФВ с шагом $\delta_k = \frac{k-1}{k+1}$ скор. сублим. с $O(\frac{1}{k})$

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}, \text{ где } R - \text{диаметр множества } S$$

41) — вып. сильно вып.: то же самое !!!

42) Субгр., субдифф.: Вектор g воз. субгр. $f(x): S \rightarrow \mathbb{R}$ в x_0 , если

$\forall x \in S \subset f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$. Субдифф $\partial f(x_0)$ — м-во всех субгра.

43) Субградиентный метод: $\min_x f(x)$, f — вып., м.д. неогр. $\hookrightarrow$

$$x_{k+1} = x_k - \alpha_k g_k, g_k \in \partial f(x_k)$$

44) Хар. сх. субгр. мет. где вып. вып. лини. ф. в терм. 0: при $\alpha \sim \frac{1}{\sqrt{k}}$

получаем $f_k^{\text{best}} - f(x^*) = O(\frac{1}{\sqrt{k}}) \Rightarrow O(\frac{1}{\varepsilon^2})$. Пример $\alpha = \frac{R}{\sqrt{k}} \Rightarrow$

$$\Rightarrow f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}, R = \|x_0 - x^*\|_2$$

45) — вып. сильно вып.: $\alpha_k = \frac{2}{\mu(k+1)} \Rightarrow \alpha \sim \frac{1}{k} \Rightarrow f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k} \Rightarrow$

$$\Rightarrow O(\frac{1}{k}) \Rightarrow \text{ускорено } O(\frac{1}{k})$$

46) Стратегия выбора шага где субгра. метод в вып. вып. лини.

Дытер.: $\sum d_k^2 < \infty$, $\sum d_k = \infty$, на пространстве $d_k = \frac{R}{\sqrt{k+1}}$

47) Континентальная оптимизация для выпукл. конв. опр. с ном. мет. I ноп. в репр. Ω : $\exists \mathcal{B}$ -мн. конъюнктов φ и ψ , что $\forall$ метог. I ноп. $x_{k+1} \in x_0 + \text{span}\{g_0, g_1, \dots, g_k\}$, $g_i \in \partial f(x_i)$ удерживать.

$$\min_{i=1, \dots, k} f(x_i) - \min f(x) \geq \frac{QR}{2(1+QR)} \Rightarrow \Omega\left(\frac{1}{\sqrt{k}}\right) \Rightarrow k \sim \Omega\left(\frac{1}{\varepsilon^2}\right)$$

48) — континентальная конв.: $f(x) = \frac{Q}{2} \max x_i + \frac{Q}{4R} \|x\|_2^2 \rightarrow \frac{Q}{2R}$ — континентальная конв.
 $\Rightarrow \min_{i=1, \dots, k} f(x_i) - f(x^*) \geq \frac{QR}{4k} \quad \forall x_{k+1} \in x_0 + \text{span}\{g_0, \dots, g_k\} \Rightarrow \Omega\left(\frac{1}{k}\right), \Omega\left(\frac{1}{\varepsilon}\right)$

49) Проекционные операторы: для f и $\alpha > 0$ проекц. опер.

$$\text{опр. } \text{prox}_{f, \alpha}(x_k) = \arg \min_x \left[f(x) + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

50) Опер. проекции как частный случай проекц. операторов.

$$\text{мысли } I_S(x) = \begin{cases} 0, & x \in S \\ \infty, & x \notin S \end{cases} \Rightarrow \text{prox}_{I_S}(y) = \text{proj}_S(y), \text{ т.к.}$$

$$\text{prox}_{I_S}(y) = \arg \min_x [I_S(y) + \frac{1}{2} \|x - y\|_2^2] = \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2 = \text{proj}_S(y)$$

51) Хар. свод. проекц. шаг. метода для максим. кон. f в репр. Ω :

где $\varphi = f + r$, где f — конв. + L -н., r — конв. и проекц. свод. — проекц. шаг. метод с $\alpha = \frac{1}{L}$ сводит. $\varphi(x_k) - \varphi^* \leq \frac{L \|x_0 - x^*\|^2}{2k} \sim O\left(\frac{1}{k}\right) \Rightarrow O\left(\frac{1}{\varepsilon}\right)$

52) — континентальная конв.: $\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$
 $k \sim O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right)$

53) Аппроксимация конв. для $\text{prox}_{\lambda \|x\|_1}$: мысли $r(x) = \lambda \|x\|_1 \Rightarrow$

$$\Rightarrow \text{задача } \arg \min_x \left[\lambda \|x\|_1 + \frac{1}{2} \|x - y\|_2^2 \right] \Rightarrow \text{реш. } [\text{prox}_r(y)]_i = \begin{cases} y_i - \lambda, & y_i > \lambda \\ 0, & |y_i| \leq \lambda \\ y_i + \lambda, & y_i < -\lambda \end{cases}$$

т.е. оператор мягкого порога

54) — для $\text{prox}_{\frac{\mu}{2} \|x\|_2^2}$: $\arg \min_x \left[\frac{\mu}{2} \|x\|_2^2 + \frac{1}{2} \|x - y\|_2^2 \right] \Rightarrow x_i = \frac{y_i}{1 + \mu}$

55) Проекц. оп. как репрод. оп.: $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq (\text{prox}_r(x) - \text{prox}_r(y))^2$

$\Rightarrow$ репрод.: $\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$, если r — конв.

56) Характеристика скорости убыв. проекц. р. мет. для максим. кон. φ в репр. Ω

$$x_k = \text{prox}_{\alpha_k r}(y_{k-1} - \alpha_k \nabla f(y_{k-1})) \quad y_k = x_k + \frac{k-1}{k+2} (x_k - x_{k-1}), \text{ где } L\text{-максим.}$$

$$f \text{ и конъюнктов проекц.-свод. } \varphi(x_k) - \varphi^* \leq \frac{2L \|x_0 - x^*\|^2}{k^2} \Rightarrow k \sim O\left(\frac{1}{\varepsilon}\right)$$

57) Метод стох. град. спуска: $\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждый шаг $p(i_k := i) = f_i$, $x_{k+1} = x_k - \alpha_k \nabla f_{i_k}(x_k)$, при равномерном выборе стох. градиент неслучайно

58) Метод мини-бatches. Эпоха: случайный SBD аппрокс. полного град. $\nabla f(x_k) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k)$ заменим $\nabla f_{i_k}(x_k)$. где мини-батч берем поочередно. B_k и упр. град. по тем $\frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(x_k) \approx \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k)$. Эпоха - один полный проход по всем батчам из n объектов (сложн. всех батчей)

59) Хар. св. SBD где m батч φ : $E(\|\nabla f_{i_k}(x_k)\|^2) \leq \sigma^2$, $\alpha = \frac{\|x_0 - x^*\|}{2\sqrt{k}}$
 где $\bar{x}_k = \frac{1}{k} \sum_{t=1}^k x_t \Rightarrow E(f(\bar{x}_k) - f^*) \leq \frac{\|x_0 - x^*\|^2}{\sqrt{k}} \sim O(\frac{1}{\sqrt{k}}) \Rightarrow O(\frac{1}{\sqrt{k}})$

60) -w где PL: $\alpha_k = \frac{2k+1}{2\mu(k+1)^2} \Rightarrow E(f(x_k) - f^*) \leq \frac{L\sigma^2}{2\mu^2 k} = O(\frac{1}{k}) \Rightarrow O(\frac{1}{k})$

61) Характер прототип SBD с пост. шагом где μ - μ PL-функции:

где L -м. PL-ф. ($\mu > 0$) при стр. выпук. стох. град. с пост. $\alpha < \frac{1}{2\mu}$
 достигается линейное до эффекта шума: $E(f(x_k) - f^*) \leq (1 - 2\mu\alpha)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}$, перв. эл. уб. темп. (лин.), эффект-шум

62) Метод SVRG: Задана $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$. Каждый шаг берем $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$, считаем $x_0 = \tilde{x}$. В каждый эпохи $t = (1, \dots, m)$ выбираем i_t равномерно и обновляем:

$x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$. В конце эпохи $\tilde{x} = x_m$
 Линейное сход. в невырожден. случае, темп $O(p)$

63) Метод SAB: хранить разницу градиентов g_i , $g_i^{(0)} = \nabla f_i(x^{(0)})$.

На шаг k выбираем случай. $i_k \Rightarrow$ выч. разн. $g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \Rightarrow$ темп. $O(p)$
 шаг $x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$. Сход. $O(\frac{1}{k})$ -темп., лин. - невырожден.

64) Adam: $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$; $m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$
 $v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$ с коррекцией $\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}$ $\hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$
 тогда $x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon}$

65) AdamW: $x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon} + \lambda x_j^{(k-1)} \right)$

66) Градиентное в Algorithm Benchmark : сравн. алг. оптимизации нелинейных по двум наборам правил : набор непрерыв. с констр. к абстрактной на отряд матрицы 3×3 ~~матрицы~~. Вектор-набор под графиком производит.

67) Сопр. норма : $\|g\|^* = \sup_{\|x\|=1} \langle g, x \rangle$

68) Linear Minimization Oracle : $LMO_{\| \cdot \|}(g) = \argmin_{\|x\|=1} \langle g, x \rangle$

69) Через LMO с сопр. нормой : $\langle g, LMO_{\| \cdot \|}(g) \rangle = -\|g\|^*$

70) Метод град. спуска : где $g = \nabla f(x_k) \leftarrow$ ^{градиент} ^{направление}
 $\leftarrow x_{k+1} = \argmin \left(f(x_k) + \langle g, x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|^2 \right) = x_k + \alpha \|g\|^* LMO_{\| \cdot \|}(g)$

71) Метод норм. г.с. : $x_{k+1} = \argmin_{\|x - x_k\| = \alpha} \left(f(x_k) + \langle g, x - x_k \rangle \right) = x_k + \alpha LMO_{\| \cdot \|}(g)$

72) Метод г.с. с матр. : $\langle A, B \rangle = \text{Tr}(A^T B) \Rightarrow w_{k+1} = \argmin_w \left[f(w_k) + \langle G_k, w - w_k \rangle + \frac{1}{2\alpha} \|w - w_k\|^2 \right] = w_k + \alpha \|G_k\|^* LMO_{\| \cdot \|}(G_k)$, $G_k = \nabla_w f(w_k)$

73) — нормир. : $w_{k+1} = \argmin_{\|w - w_k\| = \alpha} \left[f(w_k) + \langle G_k, w - w_k \rangle \right] = w_k + \alpha LMO_{\| \cdot \|}(G_k)$

74) Полнот. фактор матрицы. $G = U \Sigma V^T$ — синг. разлож. Полнот. фактор UV^T орт. тогда U и V синг. векторы, Σ и G , все синг. числа 1.

75) LMO где синг. норма : $LMO_{\| \cdot \|_2}(G) = \argmin_{\|D\|_2=1} \langle G, D \rangle = -UV^T$

76) Форм. метода норм. спуска в норм. пространстве :

$$LMO_{\| \cdot \|_F}(G) = -\frac{G}{\|G\|_F} \Rightarrow w_{k+1} = w_k - \alpha \frac{G_k}{\|G_k\|_F}$$

77) — в ∞ -норме (абсолютно) : $LMO_{\| \cdot \|_\infty}(G) = -\text{sign}(G) \Rightarrow$

$$\Rightarrow w_{k+1} = w_k - \alpha \text{sign}(G_k)$$

78) — в синг. норме : $G_k = U \Sigma V^T$, $LMO_{\| \cdot \|_2}(G) = -UV^T \Rightarrow$

$$\Rightarrow w_{k+1} = w_k - \alpha UV^T \text{ — метод иллон}$$

79) Метод иллон : поиск спуска в синг. норме, напр. шаг $-UV^T$ полное SVD $O(d^3)$ значит. Кундурин-Мундзем-С. Алгоритм : $B_0 = 0$,
 $G_k = \nabla_w L(w_{k-1}) \rightarrow B_k = \mu B_{k-1} + G_k \rightarrow O_k = \text{SVD}(B_k) \rightarrow w_k = w_{k-1} - \alpha O_k$

80) Упрощенный H-ил где воз. пол. фактор : воз. UV^T без полн. SVD, только матр. умнож. : $X_0 = G / \|G\|_F \Rightarrow x_{k+1} = \frac{1}{2} x_k (3I - x_k^T x_k) -$

сопр. интер. керн. u, v и $z \rightarrow \frac{1}{2} z (z - z^2) \Rightarrow 1 \rightarrow 1 \Rightarrow z: (x_k) \rightarrow 1, x_k \rightarrow uv^T$

На практике $x_{k+1} = \alpha x_k + \beta x_k x_k^T x_k + C (x_k x_k^T)^2 x_k$, госпат. 5 стр.

81) Углуб. проецирование ф. потерь W на прям. / плоск.: $\mathbb{R}^P \rightarrow \mathbb{R}^1 / \mathbb{R}^2$

берем век w , керн. $w_1 \in \mathbb{R}^P$ тогда керн. $\rightarrow L(\alpha) = L(w_0 + \alpha w_1)$

На плоск. 2 смысл. ($\Rightarrow$ н.н. опр.) $w_1, w_2 \Rightarrow L(\alpha, \beta) = L(w_0 + \alpha w_1 + \beta w_2)$

82) Blockking: переопред. запоздалого обд. при смысл. на редон. алг. отсечках: $\sum_{t=1}^{t_{min}} val^{loss}$ смысл. много ген. итер. оптимизации

83) Double descent:

связь bias-variance trade-off loss

Затем в непрерыв. режиме $\downarrow$

84) Углуб. grad. checkpointing:

не хранить все актуальное, а сохранять их только в $\mathbb{L}$ керн. точках и переход. ост. при обратн. проходе. Min режим - хранить $\log O(1)$, $O(L)$ переходисчетов.

85) Углуб. акк.м. градиентов: увелич. эффективный размер данных без роста потр. памяти: градиенты нескольких микрообд. разм. B , только после as итер. керна обновляются

86) Затем увеличивать данные при смысл. дальнейх моделях: полнее загруж. GPU $\Rightarrow$ эпоха прох. з меньшее число итер. оптимизации

87) Warmup: маленьких размер L от много зн. до уменьш. ко удовлет. керн.: $\alpha_t = \alpha_{max} \frac{t}{T_w}$, T_w - значительность функции

88) Масштаб. L уже больших данных: лет $\alpha_{new} = \alpha_{base} \frac{B_{new}}{B_{base}}$ - уже данных $\alpha_{new} = \alpha_{base} \sqrt{\frac{B_{new}}{B_{base}}}$ - уже экспоненциал. керн. (Adam) опт. разд. данных $5+10$ и м. обд. разм.

89) Про керн. Deepseek: $FP32 \rightarrow 1.6 \cdot 10^{12} \cdot 4B = 6.4TB$, $FP/BF16 \rightarrow 3.2TB$

90) Mixed Precision Training: forward и backward pass в $fp16/BF16$, далее зад. керн. керн. в $fp32$, при этом перед backward в

для работы без scaling т.к. числам мал диапазон $\Rightarrow$ отн. разг.

91) LoRA: при обуч. доп. можем отн. веса $W_{new} = W + \Delta W$,
 $\Delta W = AB^T$, $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$, $r \ll \min(n, m)$, A - сл.з., $B = 0$, сл.з. веса

и $\Rightarrow (m+n)r$ пар-ров вместо mn и $\Rightarrow$ меньше по вес и меньше

92) Преимущества cooldown по ср. с cosine-decay: обучаем
с высоким и больше (~90%) и меньше его по весам. Можно
пересч. checkpoints: прог. на вес. генер. з.б. cooldown может
иметь более высокую validation perplexity.

93) Метод градиент. разг. упрощен: $\min_x f(x)$, $f(x) = B \Rightarrow \max_{\nu} [\underbrace{f^*(-A^T \nu) - B^T \nu}_{g(\nu)}]$
 $g(\nu) = Ax - B$, $x \in \arg \min_{\tilde{x}} [f(\tilde{x}) + \nu^T A \tilde{x}] \Rightarrow x_k \in \arg \min_{\tilde{x}} [f(\tilde{x}) + (\nu_k)^T A \tilde{x}]$
 $\nu_k = \nu_{k-1} + \alpha_k (Ax_k - B)$

94) Число const. чисел. кон. и для f и макс. L для f^* : f convex кон.
 $\subset \mu \Leftrightarrow \nabla f^*$ linear. $L = \frac{1}{\mu}$

95) Конвекс. функции: $f^*(y) = \max_x [y^T x - f(x)]$

96) Число субгр. f и f^* : $x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x) \Leftrightarrow$

$\Rightarrow x \in \arg \min_{\tilde{x}} [f(\tilde{x}) - y^T \tilde{x}] = \nabla f^*(y)$
если оп. кон. f

97) Упрощ. dual decomposition: Задача $\min_x \sum_{i=1}^B f_i(x_i)$ при $Ax = b$,

$A = [A_1, \dots, A_B] \Rightarrow x_i^k \in \arg \min_{\tilde{x}_i} [f_i(\tilde{x}_i) + (\nu_{k-1})^T A_i \tilde{x}_i] \quad i = 1, \dots, B,$

$\nu_k = \nu_{k-1} + \alpha_k (\sum_{i=1}^B A_i x_i^k - b)$, т.е. поиск лагр. $\rightarrow$ неск. нез. перемен.

98) и для нек. оп.-вер-б: $\min_x \sum_{i=1}^B f_i(x_i)$ при $\sum_{i=1}^B A_i x_i \leq b \Rightarrow$

$\Rightarrow$ то же самое, только при опт. $\nu_k \rightarrow \max_{\nu} L_0, \nu_k$ при $Ax = b$

99) Метод модиф. q-wei лагранжа: $\min_x f(x) + \frac{p}{2} \|Ax - b\|^2$, при $\frac{p}{2}$

A матрица столб. q от кон. кон., упрощение:

$x_k = \arg \min_{\tilde{x}} [f(\tilde{x}) + \nu_{k-1}^T A \tilde{x} + \frac{p}{2} \|A \tilde{x} - b\|^2]$, $\nu_k = \nu_{k-1} + \alpha_k (Ax_k - b)$

100) ADMM: решает $\min_{x, \tilde{z}} f(x) + r(\tilde{z})$ при $Ax + B\tilde{z} = c \Rightarrow$

$\Rightarrow L_p(x, \tilde{z}, \nu) = f(x) + r(\tilde{z}) + \nu^T (Ax + B\tilde{z} - c) + \frac{p}{2} \|Ax + B\tilde{z} - c\|^2 \Rightarrow$ опт. перем.

no overpen. $x_k = \arg \min L_g(x, \bar{z}_{k-1}, \bar{v}_{k-1})$
 $\bar{z}_k = \arg \min L_g(x_{k-1}, \bar{z}, \bar{v}_{k-1})$
 $\bar{v}_k = \bar{v}_{k-1} + \rho(Ax_k + B\bar{z}_k - c)$

101) Формулы зг. мет. раун. кв. с 1-пер. в форме ADMM:

$$\min_x \frac{1}{2} \|Ax - B\|^2 + \lambda \|x\|_1, \quad f(x) = \frac{1}{2} \|Ax - B\|^2, \quad g(\bar{z}) = \lambda \|\bar{z}\|_1, \quad \text{в ADMM } \begin{matrix} A=I \\ B=-I \\ c=0 \end{matrix}$$

Уравн: $x_{k+1} = (A^T A + \rho I)^{-1} (A^T B + \rho(\bar{z}_k - u_k))$, где $\text{Sign}(v) = \text{sign } v \max(|v| - \tau, 0)$

$$\bar{z}_{k+1} = \text{Sign}(\rho(x_{k+1} + u_k))$$

$$u_{k+1} = u_k + (x_{k+1} - \bar{z}_{k+1})$$

← через нонт. шаг $\frac{+ \text{const}}{2}$
 $u^T(x - \bar{z}) + \frac{\rho}{2} \|x - \bar{z}\|^2 = \frac{\rho}{2} \|x - \bar{z} + \frac{u}{\rho}\|^2$

102) Форм. зг. раун. поиска пересет. 2 кон. м-в в форме ADMM

$$\min_{x, \bar{z}} I_U(x) + I_V(\bar{z}) \text{ при } x - \bar{z} = 0 \Rightarrow x_{k+1} = \arg \min_x [I_U(x) + y_k^T (x - \bar{z}_k) + \frac{\rho}{2} \|x - \bar{z}_k\|^2]$$

$$\Rightarrow x_{k+1} = \arg \min_{x \in U} \frac{\rho}{2} \|x - (\bar{z}_k - \frac{y_k}{\rho})\|^2 = \text{proj}_U(\bar{z}_k - \frac{y_k}{\rho}) \Rightarrow \text{3 уравн это}$$

$$x_k = P_U(\bar{z}_{k-1} - w_{k-1}), \quad \bar{z}_k = P_V(x_k + w_{k-1}), \quad w_k = w_{k-1} + x_k - \bar{z}_k \quad [\rho=1]$$

103) Форм. гр. пр. поиска: $\frac{dx}{dt} = -\nabla f(x(t))$. Если брать $\frac{x_{k+1} - x_k}{\bar{z}_{k+1} - \bar{z}_k} = -\nabla f(x_k)$

$$\alpha = \bar{z}_{k+1} - \bar{z}_k \Rightarrow x_{k+1} = x_k - \alpha \nabla f(x_k)$$

104) Хар. с. фреймворк пр. поиска где кон. ф. в терм. 0:

$$f(x(t)) - f^* \leq \frac{\|x_0 - x^*\|^2}{2t} = O\left(\frac{1}{t}\right)$$

105) — а где PL: учн. PL $\| \nabla f(x) \|^2 \geq 2\mu(f(x) - f^*) \Rightarrow$

$$\Rightarrow f(x(t)) - f^* \leq e^{-2\mu t} (f(x(0)) - f^*) - \text{экон. сход.}$$

106) Формула Нестерова уск. пр. поиска: $\ddot{x}(t) + \frac{3}{t} \dot{x}(t) + \nabla f(x(t)) = 0 \Rightarrow$

$$\Rightarrow f(x(t)) - f^* = O(1/t^2) - \text{ускоренно}$$

107) Характер... где кон. ф: $f(x(t)) - f^* \leq \frac{2\|x_0 - x^*\|^2}{t^2} = O(1/t^2)$ нонт.

108) Стох. пр. поиска: пусть $\xi \sim N(0, I^2 T) \Rightarrow dx(t) = -\nabla f(x(t))dt + \sqrt{2}dW(t)$

109) Фр-е Рунге-Кутты: $\frac{dp}{dt} = \underbrace{\nabla(p \nabla f)}_{\text{градиент мн}} + \underbrace{\frac{\sigma^2}{2} \Delta p}_{\text{дифф. в шум}}$ — экон. метр. где стох. г.н. Гаус-проц. шум

110) Прямые разм. мет. 0 поиска: зг. $\min_{x \in \mathbb{R}^n} f(x)$. GD кучебно

поиска $x_{k+1} = x_k - \alpha_k G$, G — оц. град. через f . Скорости:

$$\text{градиент} \Rightarrow \|\nabla f(x_k)\|^2 \approx O\left(\frac{n}{k}\right)$$

$$\text{градиент} + \text{воп.} \Rightarrow f(x_k) - f^* \approx O\left(\frac{n}{k}\right)$$

$$m. + \text{сильно-воп.} \Rightarrow \|x_k - x^*\|^2 \approx O\left(\left(1 - \frac{\mu}{nL}\right)^k\right) \quad \left[\text{метод 0 порожек, когда шаг неограничен} \right]$$

111) Эволюц. оп.: популяция ~~поп.~~: $x_i = \theta + z_i u_i$, $u_i \sim N(0, I)$, θ — параметр. $J(\theta) = E_u f(\theta + z_i u_i)$, $\nabla_\theta J(\theta) = \frac{1}{z} E[f(\theta + z_i u_i) u_i] \approx \frac{1}{mz} \sum_{i=1}^m f(x_i) u_i$.

ЭС — массово парам. оп. гр. J + правило отбора

112) Поиск по сетке и рандом: по сетке фикс. x_i , ищем min по ним, но при больших размерностях x растет $\uparrow$. Случайные точки по всем (гипер)осям

осей ранд. равномерное $\Rightarrow$ по закону, если их мало, покрытие хуже (или ухудшается)

113) Метод имитации ~~симуля.~~ ^{или ухаживания} ~~симуля.~~: та же k генерим соседа x^1 , $\Delta = f(x^1) - f(x_k)$. Принимаем перекос с вер. $p = \begin{cases} 1, & \Delta \leq 0 \\ \exp(-\frac{\Delta}{T_k}), & \Delta > 0 \end{cases}$

114) Метод роя частиц: у частицы поз. x_i^k , скор. v_i^k , масса m_i , мод. масса $g^k \Rightarrow v_i^{k+1} = \omega v_i^k + c_1 r_1 (p_i^k - x_i^k) + c_2 r_2 (g^k - x_i^k)$, $r_1, r_2 \sim U(0, 1)$; $x_i^{k+1} = x_i^k + v_i^{k+1}$ ^{инер.} ^{лич. ранд.} ^{соц. ранд.}

115) Марковские процессы: та пара (i, j) — переход τ_{ij} и вероятность η_{ij} (или $1/d_{ij}$ — ранд.). Вероятность перехода следующего порога: $P\{i \rightarrow j\} = \frac{\tau_{ij}^\alpha \eta_{ij}^\beta}{\sum_l \tau_{il}^\alpha \eta_{il}^\beta}$ ^{после макс. марковца} ^{усил.} $\tau_{ij} \rightarrow (1-\rho)\tau_{ij} + \Delta\tau_{ij}$

116) CMA-ES: хранит ранд. поиска $x_i^k \sim N(m_k, \Sigma_k C_k)$, $i=1, \dots, \lambda$ берем λ катог., сорт. по $f(x_i)$, $m_{k+1} = \sum_{i=1}^{\lambda} w_i x_i$ ^{м-масса} и ковариация $C_{k+1} = (1-c_1-c_\mu)C_k + \underbrace{c_1 \sigma \sigma^T}_{\text{эволюц. шаг}} + \underbrace{c_\mu \sum_{i=1}^{\lambda} w_i x_i x_i^T}_{\text{ковар. мушкетеров}}$

Пусто, т.к. по оптим. осам ф. мен. быстро, по др. медленно $\Rightarrow$ аргент.

Память $O(d^2)$ и другие недостатки

117) AlphaEvolve: эволюц. поиск, ищет не глоб. экстр. а локальный

Есть ранд. категория $\Rightarrow$ мушкетеры ИМ $\Rightarrow$ категория отбор, т.е. оценка + рандомизация $\Rightarrow$ память-бэза $\Rightarrow$ ранд. $\Rightarrow$ ищет не через тест.

